

Universidad Nacional Autónoma de México

Maestría en Ciencia e Ingeniería de la Computación

Preprocesamiento para Ciencia de Datos

Proyecto final

Calidad de datos

Integración, perfilado, limpieza y análisis de datos bibliográficos de la UNAM en Ciencias de la Computación

Estudiante: Luis David
Profesora: Dra. María del Pilar Ángeles
Periodo de datos: Marzo de 2024 a diciembre de 2025
Dominio: Producción bibliográfica/académica UNAM
Área: Ciencias de la Computación

Ciudad de México

25 de Mayo de 2026

Índice

Resumen ejecutivo	5
1. Marco teórico	6
1.1. Calidad de datos	6
1.2. Preparación de datos	6
1.3. Integración de datos heterogéneos	6
1.4. Heterogeneidad	7
1.5. Modelo canónico	7
1.6. Schema matching y schema mapping	7
1.7. Perfilado de datos	8
1.8. Limpieza de datos	8
1.9. Data matching, de-duplicación y fusión de datos	8
2. Problemática detectada	8
3. Propuesta de solución	9
3.1. Objetivo general	9
3.2. Objetivos específicos	10
3.3. Metodología	10
3.4. Preguntas descriptivas y predictivas revisadas	10
4. Arquitectura de solución propuesta	12
4.1. Aplicaciones diversas	12
4.2. Productos utilizados para la solución de cada etapa	12
4.3. Organización final de carpetas del proyecto	12
4.4. Diversas fuentes de datos	13

4.5. Cierre de la fase de recolección manual y depuración preliminar	13
4.5.1. Criterios generales aplicados en la depuración preliminar	15
4.5.2. Evidencia de la fase	15
4.5.3. Cierre metodológico de la fase	15
5. Esquemas sugeridos a todas y cada una de las fuentes de datos	15
6. Diagrama	17
7. Procedimiento para la integración de cada fuente de datos	18
7.1. Conversión canónica y clasificación de área	18
7.2. Distribución por fuente y área	19
7.3. Integración preliminar de fuentes	19
8. Procedimiento realizado para el perfilado de datos	20
8.1. Correctitud básica	21
8.2. Distribución por área y fuente	21
8.3. Duplicados candidatos	21
8.4. Diagnóstico de afiliaciones y texto	22
8.5. Dictamen del perfilado y transición a limpieza	22
9. Procedimiento realizado para la limpieza de datos	23
9.1. Objetivo y alcance de la limpieza	23
9.2. Separación artículo–autor–afiliación	23
9.2.1. Reglas de separación	24
9.2.2. Resultados de la separación	25
9.3. Normalización de afiliaciones UNAM y filtrado de autores externos	25
9.3.1. Catálogo y diccionario de afiliaciones	25
9.3.2. Reglas de normalización de afiliaciones	26

9.3.3. Resultados del filtrado UNAM	27
9.4. Normalización de columnas bibliográficas y textuales	27
9.4.1. Reglas de normalización bibliográfica y textual	28
9.4.2. Resultados de la normalización de columnas	29
9.5. Normalización de nombres de autores	29
9.5.1. Diccionario de alias de autores	30
9.5.2. Resultados de normalización de autores	30
9.6. Data matching, de-duplicación y fusión	31
9.6.1. Criterio de de-duplicación	31
9.6.2. Casos manuales revisados	32
9.6.3. Reglas de fusión de campos	32
9.6.4. Resultados de la de-duplicación y fusión	33
9.7. Curaduría manual y control de cambios	33
9.7.1. Criterios de curaduría manual	33
9.7.2. Comparación entre versión automática y versión curada	34
9.7.3. Cambios de metadatos durante la curaduría	35
9.7.4. Distribución final por área después de la curaduría	35
9.8. Validación final de la base curada	35
10.Procedimiento realizado para el análisis de datos	36
10.1. Objetivo de análisis	37
10.2. Preparación de los recursos de consulta	37
10.3. Flujo de consultas heterogéneas	37
10.4. Resultados de las preguntas descriptivas	38
10.5. Resultados de las preguntas predictivas	39
10.6. Control de calidad del LLM	40

10.7. Dictamen del análisis	40
11. Conclusiones	41

Resumen

Este proyecto se desarrolla en el dominio bibliográfico-académico de la Universidad Nacional Autónoma de México. El objetivo principal es construir un integrado bibliográfico en modelo canónico, a partir de fuentes heterogéneas, que quede perfilado, limpiado, de-duplicado y preparado para análisis posteriores. Las fuentes consideradas corresponden a bases bibliográficas y editoriales científicas, tales como Scopus, Web of Science, ACM, IEEE Xplore, Engineering Village, ScienceDirect u otras fuentes definidas en el control de datos del proyecto.

El resultado esperado es una base de datos bibliográfica en formato tabular, implementada en una estructura de grafos, con un componente textual/vectorial. La parte tabular contendrá metadatos bibliográficos; la parte textual contendrá títulos, palabras clave y resúmenes; los grafo representará relaciones entre autores, publicaciones, áreas y coautorías.

El proyecto se centra en la calidad de datos, por ello el énfasis está en integración de datos heterogéneos, correspondencia de esquemas, mapeo al modelo canónico, perfilado, limpieza, data matching, de-duplicación, fusión de datos y obtención de un registro de oro.


1. Marco teórico

1.1. Calidad de datos

La calidad de datos es un elemento central en proyectos de ciencia de datos, ya que los modelos y análisis posteriores dependen directamente de la confiabilidad, completitud, consistencia y relevancia de los datos utilizados. Una baja calidad de datos bibliográficos puede ocasionar que se omitan investigadores relevantes, que se asignen áreas incorrectas a publicaciones o que se sugieran colaboraciones académicas sin sustento.

1.2. Preparación de datos

La preparación de datos consiste en transformar datos crudos en un conjunto de datos final adecuado para análisis o modelado. La preparación incluye selección de fuentes, extracción de publicaciones, transformación al modelo canónico, limpieza, integración, de-duplicación y generación de estructuras auxiliares para texto y grafos. El flujo general aplicado es el siguiente:



1.3. Integración de datos heterogéneos

La integración de datos consiste en extraer y mezclar información proveniente de múltiples fuentes heterogéneas. Las fuentes son bases bibliográficas que pueden presentar distintos formatos de exportación, distintos nombres de columnas, diferentes reglas de representación de autores, diferencias de idioma, campos faltantes y duplicidad de publicaciones.

La integración se realiza de forma **materializada**, ya que el resultado se almacenará en un archivo final integrado bajo el modelo canónico.

1.4. Heterogeneidad

Las fuentes bibliográficas presentan heterogeneidad en varios niveles:

- a) **Heterogeneidad sintáctica:** diferencias en nombres de columnas, por ejemplo `Title`, `Article Title`, `Document Title` o `Titulo`.
- b) **Heterogeneidad estructural:** diferencias en la forma de representar autores, afiliaciones o palabras clave.
- c) **Heterogeneidad semántica:** campos que parecen equivalentes pero no significan exactamente lo mismo, por ejemplo palabras clave de autor frente a términos controlados de una base editorial.

1.5. Modelo canónico

El modelo canónico es el esquema común al que se transforman todas las fuentes antes de integrarlas. En este proyecto, el resultado final debe seguir una forma específica provista anteriormente.

Tabla 1: Modelo canónico bibliográfico

Campo	Descripción
<code>indice</code>	Identificador del artículo o registro bibliográfico.
<code>Titulo</code>	Título de la publicación.
<code>Año</code>	Año de publicación.
<code>Autor_norm</code>	Autor normalizado. Se considera una fila por relación autor-artículo.
<code>Afiliacion1</code>	Afiliación principal normalizada.
<code>Afiliacion2</code>	Afiliación secundaria, cuando exista.
<code>ISBN</code>	ISBN de la publicación, cuando aplique.
<code>ISSN</code>	ISSN de la revista o conferencia, cuando aplique.
<code>Doi</code>	Identificador DOI normalizado.
<code>URL</code>	URL de la publicación.
<code>Area</code>	Área de la maestría a la que pertenece la publicación.
<code>Subarea</code>	Subárea temática, cuando exista.
<code>Keywords</code>	Palabras clave limpias y normalizadas.
<code>Abstract</code>	Resumen de la publicación.

1.6. Schema matching y schema mapping

El *schema matching* corresponde a la identificación de atributos equivalentes entre los esquemas de las fuentes. El *schema mapping* corresponde a la transformación de esos atributos hacia el modelo canónico.

Por ejemplo, los campos `Title`, `Article Title` y `Document Title` se corresponden con `Título`. De manera similar, los campos `Authors`, `Author Names` o `Author(s)` se transforman hacia `Autor_norm`.

1.7. Perfilado de datos

El perfilado de datos permite diagnosticar la calidad de los datos antes de limpiarlos. En este proyecto, el perfilado se aplicará sobre el integrado final. Las métricas principales serán completitud, unicidad, consistencia, correctez, relevancia temática y detección de duplicados.

1.8. Limpieza de datos

La limpieza de datos se realizará con base en los problemas encontrados durante el perfilado. En este proyecto se limpiarán campos bibliográficos, autores, afiliaciones, DOI, ISBN, ISSN, palabras clave, resúmenes y registros irrelevantes.

1.9. Data matching, de-duplicación y fusión de datos

El *data matching* permite identificar registros de distintas fuentes que representan la misma publicación. La de-duplicación corresponde a la detección de duplicados dentro de una fuente o dentro del integrado. La fusión de datos permite combinar registros equivalentes en un registro limpio y consistente.

En este proyecto, la llave primaria no siempre existe o no siempre es confiable. Por ello, se utilizarán reglas de comparación basadas en DOI, título normalizado, año, autores normalizados y similitud textual.

2. Problemática detectada

La Universidad Nacional Autónoma de México cuenta con una comunidad académica amplia y distribuida en múltiples entidades, institutos, facultades, centros y áreas de conocimiento. Debido al tamaño de la institución y a la especialización de sus investigadores, un académico puede desconocer qué otros investigadores trabajan en temas compatibles o complementarios con su línea de investigación.

La problemática de negocio se puede formular de la siguiente manera:

Cuando un proyecto de investigación llega a la frontera con otra disciplina, el académico responsable puede no saber a qué investigador de la UNAM acudir para colaborar, debido a la falta de visibilidad integrada sobre publicaciones, líneas de investigación, áreas, autores y relaciones de coautoría.

Desde la perspectiva de calidad de datos, este problema se agrava porque la información bibliográfica se encuentra distribuida en múltiples fuentes editoriales y bases de datos científicas. Estas fuentes presentan heterogeneidades, duplicados, datos faltantes, variaciones en nombres de autores, afiliaciones no estandarizadas, palabras clave ruidosas y diferencias en la clasificación temática.

Si estos problemas no se corrigen, el análisis posterior puede producir resultados incorrectos, tales como:

1. Clasificar artículos fuera de Ciencias de la Computación;
2. Asignar publicaciones a un área incorrecta;
3. Omitir autores relevantes por variantes de nombre;
4. Duplicar artículos encontrados en varias fuentes;
5. Generar grafos de coautoría con nodos o relaciones incorrectas;
6. Recomendar colaboraciones académicas poco pertinentes.

Por ello, antes de cualquier modelado o análisis predictivo, es necesario construir un integrado bibliográfico limpio, consistente y trazable.

3. Propuesta de solución

La propuesta consiste en construir un proyecto de calidad de datos para integrar publicaciones académicas de la UNAM en Ciencias de la Computación, publicadas entre marzo de 2024 y diciembre de 2025, clasificadas en las seis áreas de la maestría:

Tabla 2: Áreas consideradas en el proyecto

Código	Área
ISBD	Ingeniería de Software y Bases de Datos
CC	Computación Científica
IA	Inteligencia Artificial
TC	Teoría de la Computación
SIAV	Señales, Imágenes y Ambientes Virtuales
RS	Redes y Seguridad

3.1. Objetivo general

Construir un integrado bibliográfico en modelo canónico, perfilado, limpiado, de-duplicado y preparado para análisis multimodelo, que permita estudiar producción académica y posibles colaboraciones entre investigadores de la UNAM en Ciencias de la Computación.

3.2. Objetivos específicos

1. Extraer publicaciones bibliográficas de fuentes heterogéneas.
2. Transformar cada fuente al modelo canónico.
3. Perfilar los datos en el integrado final.
4. Detectar y corregir problemas de calidad.
5. Identificar duplicados por DOI, título, año y autores.
6. Fusionar registros equivalentes para obtener un registro de oro.
7. Construir un componente de grafo para representar los metadatos de los artículos, incluida la parte textual.
8. Construir un componente de de grafo específicamente para la relación de los autores con artículos publicados en conjunto.
9. Ejecutar consultas heterogéneas.

3.3. Metodología

El proyecto seguirá las siguientes fases:

1. **Entendimiento del negocio:** definición del problema de colaboración académica.
2. **Entendimiento de los datos:** identificación de fuentes, campos, áreas y modelo canónico.
3. **Integración de datos:** correspondencia de esquemas, mapeo y transformación.
4. **Perfilado:** diagnóstico de la calidad de los datos.
5. **Limpieza:** normalización, corrección de patrones y eliminación de ruido.
6. **Data matching y de-duplicación:** detección de registros equivalentes.
7. **Fusión de datos y revicion manual:** generación del registro de oro.

3.4. Preguntas descriptivas y predictivas revisadas

Las preguntas de negocio fueron revisadas para asegurar que estuvieran alineadas con el objetivo del proyecto: apoyar la toma de decisiones sobre producción científica, relaciones entre autores, temas de investigación y posibles colaboraciones académicas dentro de la UNAM. Las preguntas se dividen en diez descriptivas y diez predictivas, y combinan componentes tabulares, textuales y de grafo.

Tabla 3: Preguntas descriptivas y predictivas revisadas del proyecto

ID	Pregunta	Posibles componentes a consultar
D1	¿Qué áreas de computación concentran más artículos por periodo de publicación?	Tabular + Grafo principal
D2	¿Qué autores tienen mayor producción dentro de cada área de conocimiento?	Tabular + Grafo principal
D3	¿Qué artículos tienen mayor número de coautores y a qué afiliaciones pertenecen esos autores?	Tabular + Grafo principal
D4	¿Qué keywords aparecen con mayor frecuencia y en qué áreas se concentran?	Tabular + Texto + Grafo principal
D5	Para la keyword <i>image processing</i> , ¿qué afiliaciones concentran más autores y artículos relacionados con ese tema?	Tabular + Texto + Grafo principal
D6	¿Qué autores conectan diferentes áreas o afiliaciones mediante sus publicaciones y coautorías?	Tabular + Grafo principal + Subgrafo de coautoría
D7	Para la keyword <i>brain</i> , ¿qué artículos la utilizan y qué autores participaron en ellos?	Texto + Grafo principal
D8	¿Qué áreas tienen producción reciente pero pocos autores asociados?	Tabular + Grafo principal
D9	¿Qué autores trabajan temas similares, según keywords y abstracts, aunque todavía no aparezcan como coautores?	Texto + Grafo principal + Subgrafo de coautoría
D10	¿Qué publicaciones parecen duplicadas o variantes del mismo artículo al comparar título, DOI, URL, abstract y autores?	Tabular + Texto
P1	Dados dos autores sin colaboración previa, ¿pueden considerarse candidatos preliminares a colaborar si comparten varias keywords en sus artículos?	Texto/Keywords + Grafo principal
P2	Para un autor poco conectado, ¿qué autores sin coautoría previa son los mejores candidatos para colaborar en el futuro?	Grafo principal + Subgrafo de coautoría
P3	¿Qué pares de autores no conectados tienen mayor posibilidad de formar una nueva colaboración académica?	Subgrafo de coautoría
P4	Para artículos relacionados con <i>image processing</i> , ¿qué pares de autores sin coautoría previa deberían recomendarse como candidatos de colaboración?	Texto + Grafo principal + Subgrafo de coautoría
P5	Dentro de una misma afiliación, ¿qué pares de autores sin colaboración previa podrían colaborar si comparten keywords en sus artículos?	Tabular + Texto + Subgrafo de coautoría
P6	Entre autores de afiliaciones distintas, ¿qué pares podrían colaborar si publican sobre keywords similares?	Tabular + Texto + Subgrafo de coautoría
P7	¿Qué autores poco conectados podrían integrarse a grupos de colaboración dentro del área de sus artículos?	Subgrafo de coautoría + Grafo principal
P8	¿Qué autores que publicaron en el mismo año y en la misma área, pero que aún no han escrito juntos, podrían considerarse candidatos de colaboración?	Tabular + Subgrafo de coautoría
P9	Dentro de la afiliación con mayor número de autores, ¿qué pares de autores de la misma área, pero sin coautoría previa, podrían revisarse como posibles colaboradores?	Tabular + Grafo principal + Subgrafo de coautoría

ID	Pregunta	Posibles componentes a consultar
P10	¿Qué pares de autores sin coautoría previa presentan alta similitud temática, pero sus artículos están clasificados en áreas diferentes?	Tabular + Texto + Subgrafo de coautoría

4. Arquitectura de solución propuesta

4.1. Aplicaciones diversas

La solución utiliza un conjunto reducido de herramientas, organizadas por función. Para extracción, transformación, perfilado, limpieza y análisis se usa **Python**; el procesamiento de CSV/XLSX y del modelo canónico se realiza con **Pandas**, mientras que **OpenPyXL** permite leer y escribir archivos Excel. Para la capa de grafos se emplea **NetworkX**; para vectorización textual, similitud y análisis exploratorio se usa **Scikit-learn**; y las visualizaciones se generan con **Matplotlib**. La ejecución y documentación técnica se desarrolla en **Jupyter Notebook**, la redacción final en **Overleaf** y el control de código, notebooks, evidencias y resultados en **GitHub**.

4.2. Productos utilizados para la solución de cada etapa

Los productos de la solución se organizaron por etapa. La extracción genera archivos crudos por fuente bibliográfica; el mapeo produce correspondencias de esquemas hacia el modelo canónico; el perfilado genera reportes de completitud, duplicados, nulos, patrones y anomalías; la limpieza produce archivos corregidos por fuente; la integración consolida el archivo canónico; la de-duplicación genera el registro de oro bibliográfico; la capa texto/vectorial produce una matriz de títulos, keywords y abstracts; la capa de grafo construye relaciones entre autores, publicaciones y colaboraciones; y el análisis utiliza consultas realizadas mediante un LLM.

4.3. Organización final de carpetas del proyecto

La organización final del proyecto se definió con base en el flujo real de trabajo: control de archivos base, recolección manual, conversión al modelo canónico, perfilado, limpieza, correcciones manuales, consultas con LLM, visualizaciones, notebooks y salidas automáticas. Esta organización permite mantener separados los recursos recolectados, los resultados intermedios y los productos finales.

La estructura quedó documentada como un árbol de trabajo, lo que facilita leer la jerarquía sin ocupar espacio con una tabla:

- 00_control/: referencias como ControldeDatos, ModeloCanónico y UNAM_Completo_Corregido.
- 01_recoleccion_manual/: bitácora, queries, reportes de búsqueda y descargas preliminares.
- 02_modelo_canonico/: archivos por fuente, archivos por área y unión preliminar canónica.

- 03_perfilado/: libreta y reportes del perfilado del integrado preliminar.
- 04_Limpieza/: separación autor–afiliación, normalización, nombres y de-duplicación.
- 05_Correcciones/: correcciones manuales, reporte de correcciones y base final corregida.
- 06_LLM/: datos, grafos y consultas para las consultas heterogéneas.
- visualizaciones/: gráficas de perfilado, limpieza, análisis y resultados.
- notebooks/: libretas de Jupyter usadas para ejecutar el flujo de trabajo.
- outputs/: reportes y salidas automáticas generadas por los notebooks.

4.4. Diversas fuentes de datos

Las fuentes de datos serán las bases bibliográficas definidas en el archivo de control de datos. Cada fuente puede contener información parcial o redundante sobre las mismas publicaciones. Por ello, se tratarán como fuentes participantes de una base heterogénea federada.

Las fuentes participantes son **Scopus**, que aporta metadatos bibliográficos, autores, afiliaciones, DOI, keywords y abstracts; **Web of Science**, que aporta metadatos complementarios, direcciones, DOI, abstracts y keywords; **ACM Digital Library**, especializada en computación y trabajada con apoyo de PDFs, BibTeX, RIS o ACM Reference Format cuando fue necesario; **IEEE Xplore**, con publicaciones de ingeniería, redes, seguridad, IA, señales, software y sistemas computacionales; **Engineering Village**, útil para ingeniería y computación pero con alta heterogeneidad y duplicación por área; **ScienceDirect**, con registros complementarios y varios casos convertidos directamente desde PDF al modelo canónico; **EBSCO**, con exportaciones tabulares y campos auxiliares de afiliación; y **ProQuest**, como fuente complementaria donde se conservaron columnas originales o unión de columnas cuando los encabezados variaron.

4.5. Cierre de la fase de recolección manual y depuración preliminar

La fase de recolección manual y depuración preliminar se organizó por editorial y por área de conocimiento. Se trabajaron ocho fuentes bibliográficas: ACM Digital Library, EBSCO Academic Search Ultimate, Engineering Village, IEEE Xplore, ProQuest Central, ScienceDirect, Scopus y Web of Science Core Collection. Para cada fuente se realizaron búsquedas orientadas a recuperar publicaciones con afiliación UNAM, dentro del periodo marzo de 2024 a diciembre de 2025 y con pertenencia clara a Ciencias de la Computación.

La recolección se estructuró en cuatro carpetas principales:

- 00_bitacora_general: contiene la bitácora general, la matriz de recolección, el manifiesto de archivos, los criterios generales de depuración, el resumen cuantitativo y los pendientes de la fase.
- 01_queries: contiene las búsquedas manuales organizadas por editorial y por área de conocimiento.

- **02_reportes_busqueda:** contiene los reportes finales de búsqueda y depuración por editorial.
- **03_descargas_raw:** contiene los archivos de datos por editorial y área después de una depuración preliminar para conservar registros de Ciencias de la Computación.

La evidencia de la fase se conserva mediante la bitácora general, las queries documentadas, los reportes de búsqueda y los archivos descargados.

En la carpeta **03_descargas** los archivos ya pasaron por una depuración preliminar. Es decir, no corresponden a los resultados sin revisar de las editoriales, sino a archivos por lote en los que se descartaron registros fuera de periodo, registros sin afiliación UNAM clara y falsos positivos que no pertenecían realmente a Ciencias de la Computación. Sin embargo, estos archivos todavía no representan el integrado final del proyecto.

Tabla 4: Resumen cuantitativo de la recolección manual y depuración preliminar

Editorial	Cargas	Duplicados internos	Únicos por lote	Aceptados CS	Formato actual	Pendiente principal
ACM Digital Library	93	24	69	57	Modelo canónico	De-duplicación global y clasificación final de área/subárea.
EBSCO	1013	38	975	129	Columnas originales + afiliaciones agregadas	Mapeo al modelo canónico y de-duplicación global.
Engineering Village	1145	638	507	142	Columnas originales	Mapeo al modelo canónico y de-duplicación global.
IEEE Xplore	832	437	395	158	Columnas originales	Mapeo al modelo canónico y de-duplicación global.
ProQuest	152	36	116	19	Columnas originales / unión de columnas	Mapeo al modelo canónico y de-duplicación global.
ScienceDirect	71	4	67	43	Modelo canónico desde PDF	De-duplicación global y clasificación final de área/subárea.
Scopus	3293	1318	1975	561	Columnas originales	Mapeo al modelo canónico y de-duplicación global.
Web of Science	4831	1306	3525	362	Columnas originales	Mapeo al modelo canónico y de-duplicación global.
Total preliminar	11430	3801	7359	1471	Heterogéneo	Integración, perfilado, limpieza y fusión.

El total de 1471 registros aceptados como Ciencias de la Computación corresponde a una suma preliminar por lotes y editoriales. Este número no debe interpretarse como el número final de artículos únicos, ya que todavía falta realizar la de-duplicación global entre áreas y entre editoriales. En esta fase la de-duplicación se aplicó principalmente dentro de cada lote o área, usando como criterio principal el DOI y, cuando no estaba disponible, una combinación de título normalizado, año y primer autor.

También debe señalarse que no todas las fuentes se encuentran en el mismo nivel de transformación. ACM y ScienceDirect fueron trabajadas en modelo canónico o canónico parcial debido a que sus metadatos se extrajeron desde PDFs, BibTeX, RIS, ACM Reference Format o referencias auxiliares. En cambio, EBSCO, Engineering Village, IEEE Xplore, ProQuest, Scopus y Web of Science conservaron sus esquemas originales de exportación, por lo que requieren una fase posterior de correspondencia de esquemas y mapeo al modelo canónico.

4.5.1. Criterios generales aplicados en la depuración preliminar

Durante la revisión de los registros se aplicaron reglas de negocio orientadas a evitar falsos positivos. Un registro se conservó únicamente cuando cumplía con los siguientes criterios:

1. El registro pertenece al periodo marzo de 2024 a diciembre de 2025.
2. El registro tiene afiliación UNAM clara o una variante institucional inequívoca.
3. El aporte principal del artículo pertenece a Ciencias de la Computación.
4. El registro contiene metadatos suficientes para justificar su inclusión.
5. El artículo puede revisarse posteriormente para asignación final de área y subárea.

Se rechazaron registros en los que términos como *software*, *database*, *algorithm*, *machine learning*, *model*, *simulation*, *image*, *signal*, *network*, *IoT*, *security*, *platform*, *Python* o *data analysis* aparecían únicamente como herramientas secundarias de otra disciplina. Esta regla fue necesaria porque varias fuentes recuperaron artículos de medicina, materiales, geociencias, energía, biología, química, ciencias sociales u otras áreas donde la computación no era la contribución central.

4.5.2. Evidencia de la fase

La fase de recolección manual se documenta mediante evidencia directa e indirecta. La evidencia directa corresponde a los archivos descargados y depurados por editorial y área. La evidencia indirecta corresponde a las queries, reportes finales, matriz de recolección, manifiesto de archivos y criterios generales de depuración.

Por esta razón, la trazabilidad de la fase se conserva en las carpetas 00_bitacora_general, 01_queries, 02_reportes_busqueda y 03_descargas.

4.5.3. Cierre metodológico de la fase

Con esta organización se cierra la fase de recolección manual y depuración preliminar. A partir de este punto, cualquier nuevo registro incorporado deberá documentarse como una modificación controlada, indicando editorial, área, query, motivo de inclusión y archivo afectado. La salida de esta fase no es todavía el integrado final.

5. Esquemas sugeridos a todas y cada una de las fuentes de datos

Cada fuente se transformará al modelo canónico. La tabla siguiente muestra la estructura de correspondencia esperada para las ocho fuentes bibliográficas consideradas: ACM, EBSCO, Engineering Village, IEEE, ProQuest, ScienceDirect, Scopus y Web of Science. Esta tabla se completará con los nombres exactos de columna de cada archivo exportado.

Tabla 5: Schema matching preliminar hacia el modelo canónico para las ocho fuentes de datos

Campo canónico	ACM	EBSCO	Engineering Village	IEEE	ProQuest	Science Direct	Scopus	WoS	Regla
Titulo	Title	Title	Title	Document Title	Title	Title	Title	Article Title	Normalizar espacios y mayúsculas.
Año	Year	Year	Year	Publication Year	Publication Year	Year	Year	Publication Year	Convertir a entero.
Autor_norm	Authors	Authors	Authors	Authors	Authors	Authors	Authors	Authors	Separar autores y generar una fila por autor.
Afiliacion1	Affiliation	Affiliation	Author affiliation	Author Affiliations	Author Affiliation	Affiliation	Affiliations	Organizations	Conservar afiliación asociada al autor cuando exista evidencia.
Afiliacion2	Affiliation	Affiliation	Author affiliation	Author Affiliations	Author Affiliation	Affiliation	Affiliations	Organizations	Usar como campo auxiliar si la fuente separa más de una afiliación.
ISBN	ISBN	ISBN	ISBN	ISBN	ISBN	ISBN	ISBN	ISBN	Validar patrón o dejar vacío.
ISSN	ISSN	ISSN	ISSN	ISSN	ISSN	ISSN	ISSN	ISSN	Validar patrón o dejar vacío.
Doi	DOI	DOI	DOI	DOI	DOI	DOI	DOI	DOI	Normalizar a minúsculas y quitar prefijos.
URL	URL	URL	URL	URL	URL	URL	Link	URL	Validar formato.
Area	Búsqueda	Búsqueda	Búsqueda	Búsqueda	Búsqueda	Búsqueda	Búsqueda	Búsqueda	Asignar con reglas de área.
Subarea	Keywords	Subjects	Controlled terms	Index Terms	Subjects	Keywords	Author Keywords	Keywords	Derivar solo si existe evidencia suficiente.
Keywords	Keywords	Subjects/Keywords	Controlled terms	Index Terms	Subjects/Keywords	Keywords	Author Keywords	Keywords	Limpiar ruido, HTML y URLs.
Abstract	Abstract	Abstract	Abstract	Abstract	Abstract	Abstract	Abstract	Abstract	Validar longitud mínima.

6. Diagrama

El modelo de datos distribuido del proyecto se representa como una base federada bibliográfica. Las fuentes bibliográficas se integran mediante un mapeo de esquemas hacia el modelo canónico tabular. A partir de este modelo canónico se construyen dos representaciones de grafo: un grafo principal, que conecta autores, artículos, keywords y afiliaciones, y un subgrafo de coautoría, que conecta autores que participaron en la misma publicación.




Figura 1: Modelo de datos distribuido: fuentes bibliográficas, modelo canónico, grafo principal y subgrafo de coautoría.

Tabla 6: Campos de unión y reglas de construcción del modelo distribuido

Campo	Uso en el modelo distribuido
Titulo	Campo común para reconocer el artículo en el modelo canónico y para agrupar autores al construir el subgrafo de coautoría.
Autor_norm	Campo de identificación de autores normalizados; se usa como nodo de autor y como base para relaciones de coautoría.
Keywords	Campo textual que se separa en términos para crear nodos de keyword y relaciones artículo-keyword.
Afiliacion1/Afiliacion2	Campos que relacionan autores con afiliaciones institucionales.
Año, ISBN, ISSN, Doi, URL, Area, Abstract	Metadatos conservados como atributos del nodo artículo.

7. Procedimiento para la integración de cada fuente de datos

Después de la recolección manual y depuración preliminar por fuente, se realizó la conversión de los archivos obtenidos al modelo canónico del proyecto. El objetivo de esta etapa fue homogeneizar la estructura de las ocho fuentes bibliográficas para que todas pudieran representarse mediante un esquema común.

El modelo canónico utilizado conserva las siguientes columnas:

indice, Titulo, Año, Autor_norm, Afiliacion1, Afiliacion2, ISBN, ISSN, Doi, URL, Area,
Subarea, Keywords, Abstract.

Durante la conversión se aplicaron reglas conservadoras: no se inventaron DOI, ISBN, ISSN, afiliaciones, autores, palabras clave, resúmenes ni subáreas; los DOI se normalizaron eliminando prefijos como <https://doi.org/>; el año se normalizó a entero cuando fue posible; y solamente se permitieron las áreas ISBD, CC, IA, TC, SIAV y RS.

7.1. Conversión canónica y clasificación de área

Después de convertir las fuentes al modelo canónico, se revisó la columna **Area** de los ocho archivos canónicos por fuente. Esta revisión se hizo con base en el contenido de cada artículo, principalmente **Titulo**, **Keywords** y **Abstract**. Como resultado, se revisaron 1,471 registros y se modificó el área de 768 registros. No se eliminaron registros por no pertenecer a Ciencias de la Computación en esta etapa, ya que la depuración temática inicial ya había conservado registros considerados pertinentes al dominio.

En total se revisaron 1,471 registros, no se eliminó ningún registro por la categoría **NO_CS** y se corrigió el área de 768 registros. Por fuente, los cambios de área fueron: ACM Digital Library, 37 de

57 registros; EBSCO, 90 de 129; Engineering Village, 76 de 142; IEEE Xplore, 103 de 158; ProQuest, 7 de 19; ScienceDirect, 22 de 43; Scopus, 260 de 561; y Web of Science, 173 de 362. Este resumen conserva la trazabilidad por fuente sin agregar otra tabla al cuerpo del documento.

La distribución final por área queda integrada en el renglón de totales de la tabla de distribución por fuente y área: ISBD con 110 registros, CC con 141, IA con 403, RS con 189, TC con 209 y SIAV con 419, para un total de 1,471 registros.

Las áreas con mayor cantidad de registros fueron SIAV e IA. Esto es consistente con la naturaleza de los artículos recuperados, ya que una parte importante de la producción reciente incluye visión computacional, procesamiento de señales, aprendizaje automático, modelos predictivos, procesamiento de lenguaje natural, optimización y sistemas inteligentes.

7.2. Distribución por fuente y área

La clasificación de área permitió obtener una distribución más consistente con el contenido real de los artículos. La tabla siguiente muestra la distribución final por fuente y área.

Tabla 7: Distribución final por fuente y área

Fuente	ISBD	CC	IA	RS	TC	SIAV	Total
ACM Digital Library	21	0	10	0	23	3	57
EBSCO	15	29	43	8	8	26	129
Engineering Village	7	16	46	18	19	36	142
IEEE Xplore	8	13	34	32	12	59	158
ProQuest	0	2	6	0	4	7	19
ScienceDirect	2	9	13	4	7	8	43
Scopus	35	48	153	72	92	161	561
Web of Science	22	24	98	55	44	119	362
Total	110	141	403	189	209	419	1471

7.3. Integración preliminar de fuentes

Una vez generados los archivos canónicos por fuente, se realizó la integración preliminar de los ocho archivos. Esta integración no incluyó limpieza profunda, de-duplicación global ni fusión de registros. Su objetivo fue validar que los archivos canónicos pudieran unirse en una sola base preliminar con estructura común. La integración encontró los ocho archivos esperados y produjo un integrado con 1,471 filas y 14 columnas canónicas. También se generó una versión con trazabilidad, que conserva columnas auxiliares para identificar la fuente, archivo de origen, área de lote e identificador de fila original.

La validación estructural de la integración confirmó que se esperaban ocho archivos y se encontraron los ocho, sin faltantes. Las filas esperadas e integradas coincidieron en 1,471; el integrado sin trazabilidad conservó 14 columnas canónicas y la versión con trazabilidad añadió cuatro columnas auxiliares hasta llegar a 18. No se detectaron problemas estructurales.

La distribución por fuente del integrado preliminar corresponde a la columna **Total** de la tabla de distribución por fuente y área: ACM Digital Library aportó 57 filas; EBSCO, 129; Engineering Village, 142; IEEE Xplore, 158; ProQuest, 19; ScienceDirect, 43; Scopus, 561; y Web of Science, 362, para un total de 1,471 filas. Esta integración confirma que el proceso de correspondencia de esquemas y mapeo al modelo canónico permitió construir una base preliminar común.

8. Procedimiento realizado para el perfilado de datos

Después de la integración preliminar, se realizó el perfilado global de la base canónica. El objetivo fue diagnosticar la calidad de los datos antes de aplicar limpieza, de-duplicación y fusión. Se concentró en completitud, correctitud básica, distribución por fuente y área, detección de duplicados candidatos.

Tabla 8: Resumen integrado de completitud del modelo canónico

Campo	Completitud	Interpretación
indice, Título, Año, Autor_norm, Area	100.0 %	Campos obligatorios completos; no hay títulos, autores, años ni áreas vacías.
Afiliacion1	99.9 %	Sólo un registro faltante.
Abstract	99.7 %	Cinco faltantes y algunos abstracts muy cortos.
Keywords	97.4 %	Treinta y ocho registros sin keywords.
Doi	96.4 %	Cincuenta y tres registros sin DOI.
Afiliacion2	1,471 faltantes	Campo completamente vacío; debe tratarse como opcional.
Subarea	1,471 faltantes	Campo completamente vacío; no aporta información en esta etapa.
ISBN	886 faltantes	Muchos artículos no tienen ISBN, por lo que no debe considerarse obligatorio.
ISSN	381 faltantes	Completitud media; puede ser útil para revistas y congresos.
URL	358 faltantes	Algunas fuentes no aportan URL; puede recuperarse desde DOI en ciertos casos.

En conjunto, la completitud es alta para los campos obligatorios del modelo canónico. Los faltantes se

concentran en campos opcionales o dependientes de la fuente, especialmente **Subarea**, **Afiliacion2**, **ISBN**, **ISSN** y **URL**.

8.1. Correctitud básica

En correctitud básica, no se detectaron años inválidos, áreas inválidas, DOI sospechosos, ISSN sospechosos, ISBN sospechosos, títulos vacíos ni autores vacíos. Las únicas observaciones fueron 7 abstracts vacíos o demasiado cortos y 38 registros sin keywords. Todos los registros tienen año 2024 o 2025: 642 registros corresponden a 2024 y 829 a 2025, para un total de 1,471.

8.2. Distribución por área y fuente

La distribución por área es válida y está más cargada hacia **SIIV** e **IA**, que juntas concentran más de la mitad de los registros. En el integrado preliminar se observaron 419 registros en **SIIV**, 403 en **IA**, 209 en **TC**, 189 en **RS**, 141 en **CC** y 110 en **ISBD**, para un total de 1,471. Esto no es necesariamente un error, pero debe considerarse al interpretar resultados posteriores, porque puede existir un sesgo temático hacia inteligencia artificial, visión, aprendizaje automático y temas cercanos.

La fuente inferida desde **indice** muestra una concentración fuerte en Scopus y Web of Science. La distribución por fuente fue: Scopus, 561 registros; Web of Science, 362; IEEE Xplore, 158; Engineering Village, 142; EBSCO, 129; ACM Digital Library, 57; ScienceDirect, 43; y ProQuest, 19. Esta concentración explica en buena medida el alto número de duplicados, porque un mismo artículo puede aparecer en varias bases bibliográficas.

8.3. Duplicados candidatos

El hallazgo más importante del perfilado fue la alta duplicación entre fuentes. Esta duplicación no se interpreta como error de captura, sino como consecuencia normal de integrar múltiples bases bibliográficas que indexan los mismos artículos.

Tabla 9: Duplicados candidatos detectados

Criterio	Registros candidatos
DOI normalizado	1324
Título normalizado + año	1363
Título normalizado + año + primer autor	1313
Grupos candidatos por DOI	297

La presencia de 297 grupos candidatos duplicados por DOI confirma que el principal problema de calidad del integrado preliminar es una inconsistencia extensional: el mismo artículo aparece representado varias veces en distintas fuentes bibliográficas. Por tanto, la siguiente fase debe enfocarse en data matching, de-duplicación, fusión de registros y obtención del registro de oro.

8.4. Diagnóstico de afiliaciones y texto

El campo **Autor_norm** está completo al 100 %. En afiliaciones, se encontró un registro con **Afiliacion1** faltante y 22 registros donde no se detectó evidencia clara de UNAM con la regla de perfilado. Estos casos requieren revisión durante la limpieza, ya que pueden deberse a variantes de escritura, acentos, codificación, errores tipográficos o formas institucionales alternativas.

En los campos textuales, los problemas fueron puntuales: 38 registros sin keywords, 7 abstracts vacíos o demasiado cortos, 27 registros con URLs en **Keywords** o **Abstract**, y 16 registros con posibles etiquetas HTML en campos textuales. No se detectaron problemas graves de caracteres raros ni saltos de línea generalizados.

Las keywords frecuentes son coherentes con el dominio de Ciencias de la Computación. Entre los términos más frecuentes se encuentran *deep learning*, *machine learning*, *convolutional neural networks*, *artificial intelligence*, *neural networks*, *computer vision*, *reinforcement learning*, *graph neural networks* y *multi objective optimization*. Esto sugiere que el contenido integrado es temáticamente relacionado con el dominio del proyecto.

8.5. Dictamen del perfilado y transición a limpieza

El perfilado global permite concluir que la base integrada preliminar es apta para pasar a limpieza. La estructura canónica es correcta, los años y áreas son válidos, los títulos y autores están completos, y los identificadores presentes no muestran problemas de formato básicos. Sin embargo, la base todavía no puede considerarse limpia debido a la alta duplicación multifuente y a problemas secundarios de completitud y texto.

La fase de limpieza debe priorizar:

1. de-duplicación global por DOI normalizado;
2. de-duplicación secundaria por título normalizado, año y primer autor;
3. consolidación de campos complementarios entre fuentes;
4. normalización de afiliaciones y confirmación de evidencia UNAM;
5. limpieza ligera de **Keywords** y **Abstract**;
6. decisión sobre campos opcionales como **Subarea**, **Afiliacion2**, **ISBN**, **ISSN** y **URL**.

Por tanto, la siguiente etapa corresponde a limpieza global, data matching, fusión de datos y obtención del registro de oro.

9. Procedimiento realizado para la limpieza de datos

La limpieza de datos se realizó después del perfilado global del integrado preliminar. El objetivo fue transformar una base canónica integrada, todavía redundante y con autores/afiliaciones agregados, en una base final limpia, normalizada, filtrada a autores UNAM, de-duplicada, fusionada y curada manualmente.

Esta fase se ejecutó de manera incremental para reducir riesgos: primero se separó la relación artículo–autor–afiliación; después se filtraron y normalizaron afiliaciones UNAM; posteriormente se estandarizaron columnas bibliográficas y textuales; más adelante se normalizaron nombres de autores; después se realizó la de-duplicación y fusión automática; finalmente se aplicó una curaduría manual para corregir relaciones artículo–autor, afiliaciones específicas, duplicados residuales y metadatos antes de declarar el registro de oro.

9.1. Objetivo y alcance de la limpieza

La base integrada preliminar contenía 1,471 registros canónicos y 14 columnas. En esta etapa se buscó resolver problemas de calidad detectados durante el perfilado, principalmente:

1. autores múltiples contenidos en una sola celda;
2. afiliaciones con formatos heterogéneos por fuente;
3. autores externos mezclados con autores UNAM;
4. variantes de afiliaciones de la Universidad Nacional Autónoma de México;
5. valores bibliográficos con formatos no homogéneos;
6. keywords y abstracts con ruido textual;
7. variantes en nombres de autores;
8. duplicados producidos por la integración de varias fuentes bibliográficas;
9. conflictos entre metadatos equivalentes provenientes de distintas fuentes.

El modelo canónico se conservó durante todo el proceso con las siguientes columnas:

indice, Titulo, Año, Autor_norm, Afiliacion1, Afiliacion2, ISBN, ISSN, Doi, URL, Area,
Subarea, Keywords, Abstract.

9.2. Separación artículo–autor–afiliación

La primera subfase consistió en transformar la base canónica integrada preliminar en una base expandida donde cada fila representara la relación artículo–autor–afiliación. Esta transformación

fue necesaria porque en la base preliminar la columna **Autor_norm** podía contener varios autores separados por punto y coma, mientras que **Afiliacion1** podía contener listas de afiliaciones con formatos diferentes según la fuente bibliográfica.

La entrada fue:

```
02_modelo_canonico/03_union/integrado_preliminar_canonico.csv
```

La libreta final usada fue:

```
04_limpieza_00_separacion_autor_afiliacion_reglas_explicitas.ipynb
```

El archivo elegido para continuar fue:

```
integrado_articulo_autor_afiliacion_unificado_manual.csv
```

9.2.1. Reglas de separación

El criterio central fue separar autores principalmente por punto y coma. No se separaron autores por coma, porque en muchas fuentes los nombres aparecen en formato *Apellido, Nombre*. Por ejemplo, en un valor como “Castañeda, Armando; Rajsbaum, Sergio”, el punto y coma separa autores, mientras que la coma forma parte del nombre.

Las reglas se definieron por fuente porque los patrones de autor–afiliación no fueron homogéneos entre editoriales. En **ACM** se procesaron patrones como *Autor: Afiliación* y marcadores numéricos de afiliación, priorizando afiliaciones UNAM cuando existían más de dos. En **EBSCO** se separaron bloques *Autor — Afiliación* mediante separador vertical y se asignó la afiliación por posición o coincidencia de nombre.

En **Engineering Village** se interpretaron marcadores numerados como *(1)*, *(2)* o *(3)*, evitando separar afiliaciones por punto y coma porque podían ser parte de direcciones. En **IEEE Xplore** se separaron autores y afiliaciones por punto y coma y, cuando el número coincidía, se asignaron por posición. En **ProQuest** se separaron bloques de afiliación por coma con espacios cuando funcionaban como separadores de bloque, sin dividir direcciones internas por coma simple.

En **ScienceDirect** se procesaron patrones *Autor: Afiliación* y *Autor — Afiliación*, con coincidencia de nombre y orden cuando fue necesario. En **Scopus** se combinaron reglas por posición, afiliación compartida, historial interno de autor y similitud de afiliación, usando fallback por bloques en casos ambiguos. En **Web of Science** se procesaron bloques explícitos de autores y afiliaciones, y en casos ambiguos se usó posición, memoria interna de autor y similitud de afiliación.

9.2.2. Resultados de la separación

Tabla 10: Resultado de separación artículo–autor–afiliación

Métrica	Valor
Artículos originales integrados	1,471
Artículos únicos en salida	1,471
Filas finales artículo–autor	8,940
Filas con alguna afiliación	8,940
Filas sin afiliación	0
Filas con <code>Afiliacion2</code> usada	273
Placeholders restantes	0
Columnas finales	14

La salida unificada fue validada contra la unión de los ocho archivos separados por editorial. La comparación produjo 8,940 filas en ambos casos y no se detectaron diferencias, por lo que el flujo unificado reproduce correctamente el procesamiento individual por fuente. La expansión por fuente fue: ACM, 57 artículos y 191 filas autor–artículo; EBSCO, 129 y 498; Engineering Village, 142 y 767; IEEE Xplore, 158 y 960; ProQuest, 19 y 94; ScienceDirect, 43 y 188; Scopus, 561 y 4,296; y Web of Science, 362 y 1,946. En total, los 1,471 artículos originaron 8,940 filas autor–artículo.

9.3. Normalización de afiliaciones UNAM y filtrado de autores externos

Después de separar artículo–autor–afiliación, se normalizaron las afiliaciones UNAM y se filtraron autores externos. La finalidad fue conservar únicamente las filas correspondientes a autores con alguna afiliación asociada a la Universidad Nacional Autónoma de México.

La entrada fue:

```
integrado_articulo_autor_afiliacion_unificado_manual.csv
```

La salida final fue:

```
integrado_solo_unam_normalizado.csv
```

9.3.1. Catálogo y diccionario de afiliaciones

Para normalizar las afiliaciones se construyó un catálogo institucional a partir de la base de referencia `UNAM_Completo_Corregido.xlsx`. Esta base no contiene necesariamente los mismos artículos del periodo actual, pero sí sirvió como estándar para identificar nombres de organismos, institutos, facultades, centros, escuelas, unidades y direcciones generales.

El proceso se dividió en tres libretas principales:

1. `04_limpieza_01_catalogo_afiliaciones_unam_campus.ipynb`: construcción del catálogo inicial de organismos, alias, programas y casos de revisión.
2. `04_limpieza_02_catalogo_diccionario_afiliaciones_unam_final.ipynb`: consolidación del catálogo y diccionario final.
3. `04_limpieza_03_normalizar_filtrar_afiliaciones_unam.ipynb`: aplicación del diccionario a la base artículo–autor–afiliación y eliminación de autores externos.

El catálogo final tuvo 89 afiliaciones normalizadas y el diccionario final tuvo 261 alias. Se aplicó la regla de que la afiliación final no debía contener comas, para evitar dejar direcciones largas como afiliación normalizada.

9.3.2. Reglas de normalización de afiliaciones

Las reglas de normalización de afiliaciones fueron las siguientes:

- Cuando se detectó una afiliación específica, se reemplazó por el nombre normalizado del catálogo.
- La afiliación genérica *Universidad Nacional Autonoma de Mexico* se conservó sólo cuando no fue posible identificar una dependencia más específica.
- Los programas y posgrados se trataron preferentemente como alias hacia organismos, no como afiliaciones finales.
- Las sedes, campus o unidades se conservaron cuando formaban parte de un nombre institucional útil, por ejemplo Unidad Yucatán, Unidad Juriquilla, Unidad Mérida o Cuernavaca.
- Las afiliaciones externas se eliminaron de la base final de esta etapa.
- Las direcciones largas no se conservaron como afiliación final, sino que se reemplazaron por la dependencia normalizada.

9.3.3. Resultados del filtrado UNAM

Tabla 11: Resultado de normalización de afiliaciones y filtrado UNAM

Métrica	Valor
Filas originales artículo-autor	8,940
Filas conservadas con asociación UNAM	3,239
Filas eliminadas por no tener asociación UNAM	5,701
Artículos con al menos un autor UNAM conservado	1,459
Columnas finales	14
Afiliaciones normalizadas distintas	48
Filas con Afiliacion2 normalizada	82
Filas finales sin Afiliacion1	0
Afiliaciones finales con coma	0
Afiliaciones finales fuera del catálogo	0

Las afiliaciones más frecuentes después de la normalización fueron *Universidad Nacional Autonoma de Mexico, Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas, Facultad de Ingeniería, Facultad de Ciencias, Facultad de Estudios Superiores Aragón, Instituto de Matemáticas e Instituto de Ingeniería*. La presencia de la afiliación genérica se mantuvo únicamente como respaldo cuando existía evidencia UNAM pero no era posible asignar una dependencia más específica.

9.4. Normalización de columnas bibliográficas y textuales

La siguiente subfase estandarizó las columnas bibliográficas y textuales de la base ya filtrada a autores UNAM, sin deduplicar ni fusionar registros y sin normalizar todavía la columna **Autor_norm**. La entrada fue:

```
integrado_solo_unam_normalizado.csv
```

La salida final elegida fue:

```
integrado_solo_unam_estandarizado_pre_deduplicacion_limpio.csv
```

Las libretas usadas fueron:

1. 04_limpieza_04_normalizar_columnas_pre_deduplicacion_v2.ipynb
2. 04_limpieza_05_corregir_observaciones_pre_deduplicacion.ipynb

9.4.1. Reglas de normalización bibliográfica y textual

Las reglas de normalización bibliográfica y textual se aplicaron por campo:

- **indice:** se estandarizó como entero en texto, sin decimales. Puede repetirse en varias filas autor-artículo.
- **Título:** se limpiaron espacios dobles, saltos de línea y espacios al inicio o final. También se protegieron acrónimos técnicos y casos puntuales como *NeuralODE*.
- **Año:** se extrajo en cuatro dígitos y sólo se conservaron valores correspondientes a 2024 y 2025.
- **ISBN:** se trató como texto, sin etiquetas ni notación científica. Se validaron ISBN-10 e ISBN-13, y los valores múltiples se separaron con coma y espacio.
- **ISSN:** se normalizó al formato #####-####, permitiendo una X final.
- **Doi:** se normalizó a minúsculas, se eliminaron prefijos como <https://doi.org/>, <http://dx.doi.org/>, doi.org/ y [doi:](https://doi.org/), y sólo se conservaron valores iniciados en 10..
- **URL:** se conservaron URL válidas. Cuando la URL estaba vacía pero existía un DOI limpio, se generó una URL con el formato <https://doi.org/DOI>.
- **Keywords:** se normalizaron separadores y se eliminaron etiquetas editoriales, HTML, URLs, basura editorial y palabras clave duplicadas.
- **Abstract:** se eliminaron etiquetas iniciales, HTML, espacios dobles, copyright residual, URLs de disponibilidad, residuos LaTeX y bloques no académicos.
- **Subarea:** se dejó vacía por regla del proyecto.
- **Autor_norm:** no se modificó en esta subfase, porque se normalizó posteriormente con un diccionario específico.

9.4.2. Resultados de la normalización de columnas

Tabla 12: Métricas finales después de normalizar columnas bibliográficas y textuales

Métrica	Valor
Filas	3,239
Columnas	14
Artículos únicos por índice	1,459
Año 2024	1,399
Año 2025	1,840
DOI no vacíos	3,079
DOI vacíos	160
URL vacías	74
DOI no vacío con URL vacía	0
ISBN no vacíos	1,293
ISSN no vacíos	2,350
Keywords vacías	103
Abstract vacíos	8
Afiliacion1 vacía	0
Afiliacion2 usada	82
Subarea no vacía	0

La normalización redujo de forma importante los problemas de URL: la base de entrada tenía 837 URL vacías, mientras que la salida final de esta subfase tuvo 74 URL vacías. Esto se logró al construir URL a partir de DOI cuando fue posible. El aumento de keywords vacías de 98 a 103 fue intencional, porque algunas keywords residuales correspondían a basura editorial o términos no informativos.

9.5. Normalización de nombres de autores

Una vez estandarizadas las columnas bibliográficas y textuales, se normalizó la columna **Autor_norm**. Esta fase fue especialmente delicada porque los autores podían aparecer con iniciales, formato invertido, acentos inconsistentes, puntos, comas, guiones o variantes entre fuentes.

La entrada fue:

```
integrado_solo_unam_estandarizado_pre_deduplicacion_limpio.csv
```

La salida final fue:

```
integrado_solo_unam_autores_normalizados.csv
```

El proceso utilizó la base actual del proyecto y la base de referencia `UNAM_Completo_Corregido.xlsx`. Esta última se usó como estándar de estilo, no como lista cerrada de autores.

9.5.1. Diccionario de alias de autores

La normalización se realizó en dos pasos:

1. creación de un diccionario inicial de alias y una lista de autores sin coincidencia segura;
2. corrección manual del diccionario y aplicación a toda la base.

Las libretas usadas fueron:

1. `04_limpieza_06_crear_diccionario_autores_unam.ipynb`
2. `04_limpieza_07_normalizar_nombres_autores.ipynb`

El diccionario final corregido fue:

`diccionario_alias_autores_unam_final_corregido.csv`

El diccionario final incluyó 1,844 filas, 1,844 alias únicos exactos, 1,844 alias únicos normalizados, 743 autores normalizados únicos exactos y 743 autores normalizados únicos por clave normalizada. No quedaron alias vacíos, autores normalizados vacíos, conflictos de alias hacia más de un autor ni duplicados exactos de filas. La cobertura fue completa: 3,239 de 3,239 filas de la base y 938 de 938 autores únicos quedaron cubiertos.

9.5.2. Resultados de normalización de autores

Tabla 13: Comparación antes y después de normalizar autores

Métrica	Antes	Después
Filas	3,239	3,237
Columnas	14	14
Autores únicos exactos	1,112	743
Autores únicos por clave normalizada	938	743
Artículos únicos por <code>indice</code>	1,459	1,459
Filas eliminadas por exclusión manual	0	2

La reducción de variantes de autor fue significativa. Antes de normalizar existían 1,112 valores exactos distintos en `Autor_norm`; después de aplicar el diccionario quedaron 743 autores normalizados.

También se validó que la columna final no conservara problemas básicos: no quedaron autores con comas, puntos, dígitos, corchetes, paréntesis, asteriscos ni punto y coma.

Se aplicó una exclusión manual específica: dos filas asociadas al autor *Ramos, R.* que tenía el DOI de 10.1109/oceans55160.2024.10754153 fueron eliminadas porque no correspondían a un autor UNAM. Esta eliminación se realizó en la fase de autores porque afectaba directamente la columna `Autor_norm` y evitaba conservar un autor externo.

9.6. Data matching, de-duplicación y fusión

La última subfase de limpieza fue la de-duplicación y fusión de artículos. Su objetivo fue reducir duplicados producidos por la integración de múltiples fuentes bibliográficas, conservando una base final en formato artículo–autor: una fila por autor UNAM asociado a cada artículo final deduplicado.

La entrada fue:

```
integrado_solo_unam_autores_normalizados.csv
```

La salida final seleccionada fue:

```
integrado_solo_unam_deduplicado_fusionado.csv
```

La libreta usada fue:

```
04_limpieza_08_deduplicar_fusionar_pares.ipynb
```

9.6.1. Criterio de de-duplicación

A diferencia de la propuesta inicial, en esta fase no se usó DOI como llave principal. La razón es que un mismo artículo podía aparecer en diferentes fuentes con DOI distinto, DOI editorial, DOI de proceedings, DOI de arXiv o variaciones bibliográficas. Por ello, el criterio principal final fue:

título normalizado + año + autor normalizado

El DOI se conservó como dato bibliográfico a fusionar, pero no como criterio principal de unión. Los criterios de data matching quedaron organizados así: el criterio principal fue mismo título normalizado, mismo año y mismo autor; como criterio complementario se usó mismo título normalizado y mismo año para identificar grupos por artículo; como criterio auxiliar se empleó mismo título normalizado y autor compartido cuando el año difería entre 2024 y 2025; para variantes textuales menores se revisó título muy similar, mismo año y autor compartido; cuatro equivalencias manuales se trataron como criterio controlado; y el DOI se usó únicamente como metadato a fusionar, no como llave principal.

9.6.2. Casos manuales revisados

Se incorporaron reglas manuales para cuatro grupos donde el mismo artículo aparecía con variantes de título, año o forma textual. Estas fusiones sólo se aplicaron cuando existía compatibilidad de autor.

1. *Finding locally optimal solutions for multiobjective multimodal optimization.*
2. *Finding the set of nearly optimal solutions of a multiobjective optimization problem.*
3. *Solution algorithms for the capacitated location-tree problem with interconnections.*
4. *Towards a collaborative game designer using the CCDSF framework.*

9.6.3. Reglas de fusión de campos

Las reglas de fusión se aplicaron por campo:

- **Título:** se conservó la versión más limpia, menos ruidosa y más informativa.
- **Año:** se seleccionó el valor con mayor soporte dentro del grupo fusionado. Los conflictos entre 2024 y 2025 se documentaron.
- **Autor_norm:** se conservaron autores UNAM normalizados. Si el mismo autor aparecía repetido dentro del mismo artículo, se fusionó en una sola fila.
- **Afiliacion1 y Afiliacion2:** se priorizaron afiliaciones específicas sobre *Universidad Nacional Autonoma de Mexico*. Cuando había dos afiliaciones UNAM específicas distintas, se usaron ambas columnas.
- **ISBN e ISSN:** se conservaron valores únicos fusionados.
- **Doi:** se eligió un DOI final cuando existía. Los DOI restantes del grupo se documentaron en diagnóstico.
- **URL:** se priorizó la URL derivada del DOI final cuando correspondía.
- **Area:** se conservó un solo código válido del catálogo. Los conflictos de área se documentaron.
- **Subarea:** se mantuvo vacía.
- **Keywords:** se fusionaron y deduplicaron las palabras clave de las fuentes disponibles.
- **Abstract:** se conservó el resumen más completo.

9.6.4. Resultados de la de-duplicación y fusión

Tabla 14: Resultados cuantitativos de de-duplicación y fusión

Métrica	Valor
Filas artículo–autor antes de de-duplicar	3,237
Artículos originales por índice	1,459
Artículos finales deduplicados	410
Filas finales artículo–autor	1,070
Filas artículo–autor reducidas	2,167
Artículos reducidos	1,049
Clusters con duplicados	305
Índices originales dentro de clusters duplicados	1,354
Autores únicos finales	738
DOI únicos finales no vacíos	387
Artículos finales sin DOI	23
Filas finales con <code>Afiliacion2</code>	61
Afiliaciones genéricas UNAM antes de fusionar	1,241
Afiliaciones genéricas UNAM después de fusionar	301

El proceso redujo la base de 1,459 artículos originales por índice a 410 artículos finales deduplicados, y de 3,237 filas artículo–autor a 1,070 filas finales artículo–autor. Esta reducción refleja la alta redundancia que existía entre fuentes bibliográficas.

9.7. Curaduría manual y control de cambios

Después de la de-duplicación y fusión automática se realizó una curaduría manual controlada. Esta etapa no sustituyó el procedimiento automático, sino que lo auditó y corrigió en los casos donde la relación artículo–autor–afiliación todavía requería decisión humana. El objetivo fue asegurar que la base final conservara únicamente relaciones artículo–autor con adscripción UNAM verificable, corregir autores omitidos o mal asignados, normalizar nombres y afiliaciones, resolver duplicados residuales, reordenar el índice con lógica artículo–autor y conservar las 14 columnas canónicas.

La curaduría se aplicó sobre la unidad de decisión artículo–autor. Por esta razón, no se eliminó ningún autor de forma global sólo por su nombre. Un mismo nombre podía ser externo en un artículo y UNAM en otro; por tanto, la decisión de conservar o eliminar se tomó únicamente para el par artículo–autor revisado.

9.7.1. Criterios de curaduría manual

Los criterios de curaduría manual se aplicaron de forma conservadora. Se conservó una fila únicamente cuando el autor estaba asociado a una adscripción UNAM comprobable para ese artículo. Se eliminó una fila cuando la afiliación correspondía a otra institución, cuando el autor no aparecía

como autor UNAM del trabajo o cuando la fila era una variante duplicada dentro del mismo artículo. Se agregó una fila cuando el artículo tenía participación UNAM pero el autor UNAM no estaba representado. Para normalizar autores, si el autor estaba en la base institucional de referencia se usó esa forma de nombre; si era nuevo, se usó la forma más completa disponible y, por regla general, sin acentos. En afiliación se priorizaron dependencias universitarias específicas, como institutos, facultades, centros, escuelas o unidades académicas, y los programas académicos se usaron sólo como evidencia para ubicar la dependencia responsable. En metadatos no se inventó información: DOI, URL, ISBN, ISSN, keywords y abstracts sólo se conservaron o completaron cuando existía evidencia suficiente en registros canónicos, PDF o metadatos editoriales revisados.

9.7.2. Comparación entre versión automática y versión curada

El control de cambios comparó la versión automática de trabajo contra la versión curada. La reducción de filas y autores no representa una pérdida masiva de artículos, sino principalmente la eliminación de coautores externos, la normalización de variantes de nombre y la fusión de duplicados residuales.

Tabla 15: Comparación general entre versión automática y versión curada

Métrica	Versión automática	Versión curada	Diferencia
Filas artículo–autor	1,072	905	-167
Artículos únicos	412	406	-6
Artículos normalizados únicos	410	406	-4
Autores únicos	738	550	-188
Pares artículo–autor	1,072	905	-167

Durante la curaduría se compararon 1,072 pares artículo–autor de la versión automática contra 905 pares de la versión curada. Se conservaron 684 pares sin cambio de autor normalizado; 388 pares presentes en la versión automática ya no quedaron en la versión curada; y se incorporaron o corrigieron 221 pares. Los 406 artículos compartidos por título normalizado se distribuyeron así: 170 conservaron el mismo conjunto de autores, 236 tuvieron cambios en autores, 115 quedaron con menos autores, 24 quedaron con más autores y 97 conservaron el mismo número de autores pero con nombres corregidos o sustituidos.

Para controlar el proceso, la revisión se dividió por rangos de índices. En cada bloque se revisaron autores, afiliaciones y metadatos antes de decidir conservar, eliminar, agregar o corregir registros.

La revisión también permitió identificar cuatro títulos ausentes respecto a la versión automática. Estos casos se consideraron exclusiones o decisiones donde no se cumplió la regla de conservación de autoría UNAM verificable para el artículo correspondiente.

9.7.3. Cambios de metadatos durante la curaduría

Además de corregir autores y afiliaciones, la curaduría ajustó metadatos bibliográficos cuando existía evidencia suficiente. El cambio más frecuente ocurrió en URL, porque se corrigió la regla de conservación: cuando existía URL original en los registros canónicos, se conservó esa URL; sólo se construyó una URL a partir del DOI cuando no había una URL original disponible.

Tabla 16: Artículos compartidos con cambios de metadatos durante la curaduría

Campo	Artículos con cambio
Titulo	4
Año	0
ISBN	0
ISSN	2
Doi	12
URL	357
Area	17
Subarea	0
Keywords	6
Abstract	5

9.7.4. Distribución final por área después de la curaduría

La curaduría eliminó áreas combinadas que todavía existían en la versión automática. Cada fila final quedó asignada a un solo valor permitido: ISBD, CC, IA, TC, SIAV o RS.

Tabla 17: Distribución final por área después de la curaduría

Área	Versión automática	Versión curada	Diferencia
ISBD	62	59	-3
CC	107	91	-16
IA	293	278	-15
TC	94	92	-2
SIAV	389	314	-75
RS	87	71	-16
Áreas combinadas	40	0	-40

9.8. Validación final de la base curada

La base final seleccionada después de la curaduría manual fue:

05_Correcciones/UNAM_Completo_2024_2025.csv

Esta versión ya no debe interpretarse como una salida automática directa, sino como una base curada y auditada. Conserva las 14 columnas canónicas, mantiene la lógica artículo–autor, no contiene

duplicados de `indice + Autor_norm`, no tiene filas sin autor ni sin afiliación principal, no conserva áreas combinadas y presenta URL completas para todos los registros.

Tabla 18: Validaciones estructurales finales de la base curada

Validación	Resultado
Columnas canónicas exactas	Sí
Columnas finales	14
Filas artículo–autor	905
Artículos únicos	406
Índices únicos	406
Autores únicos	550
Subarea vacía	Sí
Índice consecutivo por artículo	Sí
Duplicados <code>indice + Autor_norm</code>	0
Filas sin autor	0
Filas sin afiliación principal	0
Áreas fuera de catálogo	0
URL vacías	0
Filas con afiliación genérica principal	59

La limpieza permitió pasar de una base canónica integrada preliminar a una base curada, con autores UNAM verificados y lista para el análisis multimodelo. La transformación principal puede resumirse de la siguiente manera: se partió de 1,471 artículos integrados, la separación artículo–autor produjo 8,940 filas, el filtrado UNAM conservó 3,239 filas, la normalización de autores dejó 3,237 filas, la de-duplicación y fusión produjo 1,070 filas artículo–autor, y la curaduría manual cerró el registro de oro con 905 filas artículo–autor, 406 artículos únicos y 550 autores únicos.

La versión final curada es el registro de oro de esta etapa del proyecto. La reducción de registros no fue arbitraria: se debió principalmente a la eliminación de coautores externos, la incorporación de autores UNAM faltantes, la normalización de nombres y afiliaciones, la corrección de metadatos y la resolución de duplicados residuales. Con esta base se puede continuar hacia la construcción del grafo principal, el subgrafo de coautoría, el componente textual/vectorial y las consultas heterogéneas.

10. Procedimiento realizado para el análisis de datos

El análisis se realizó después de cerrar la base limpia y curada. La entrada principal fue el archivo:

05_Correcciones/UNAM_Completo_2024_2025.csv

Esta base contiene 905 filas artículo–autor, 406 artículos únicos y 550 autores únicos. A diferencia de las etapas anteriores, en esta fase no se modificó la base canónica: únicamente se generaron estructuras derivadas para responder preguntas descriptivas y predictivas mediante consultas tabulares, textuales y de grafo.

10.1. Objetivo de análisis

El objetivo de esta etapa fue resolver las 20 preguntas revisadas del proyecto mediante consultas heterogéneas. Para ello, se prepararon tres fuentes de consulta locales:

- **SQLite:** base tabular con la tabla `articulos_autores`, útil para conteos, filtros por año, área, autor, afiliación y distribución de publicaciones.
- **TF-IDF:** representación textual/vectorial construida a partir de `Título`, `Keywords` y `Abstract`, útil para búsqueda temática y similitud entre artículos o autores.
- **NetworkX:** grafo principal y subgrafo de coautoría, útiles para consultar relaciones entre autores, artículos, keywords, afiliaciones y colaboraciones.

Además, se utilizó un LLM local mediante Ollama, con el modelo `qwen2.5:7b`, como capa de redacción final. El LLM no se usó como fuente de datos; las respuestas se generaron a partir de evidencia calculada previamente con SQL, NetworkX y TF-IDF.

10.2. Preparación de los recursos de consulta

La base SQLite se creó con una sola tabla física llamada `articulos_autores`. Esta tabla conserva las 14 columnas canónicas y mantiene la unidad artículo–autor. Para acelerar las consultas frecuentes, se crearon índices sobre `indice`, `Autor_norm`, `Area`, `Año` y `Título`.

Para la capa textual, se construyeron dos índices TF-IDF: uno por artículo y otro por autor. El índice por artículo tiene dimensión 406×30000 , mientras que el índice por autor tiene dimensión 550×30000 . Se usó una representación combinada en la que el título recibió peso 3, las keywords peso 4 y el abstract peso 1. Esta ponderación se eligió porque las keywords suelen representar mejor el tema central del artículo, mientras que el abstract aporta contexto adicional.

Para la capa de grafos, se generó un grafo principal con 3,896 nodos y 5,078 aristas. Este grafo incluye nodos de tipo artículo, autor, keyword y afiliación. También se creó un subgrafo de coautoría con 550 autores, 827 aristas, 173 componentes conexas y una componente mayor de 60 autores. Esta separación permitió distinguir entre consultas generales de relación artículo–autor–keyword–afiliación y consultas específicas de colaboración entre autores.

10.3. Flujo de consultas heterogéneas

El flujo aplicado en esta etapa fue el siguiente:

pregunta en lenguaje natural $\rightarrow$ selección de motores $\rightarrow$ ejecución SQL/NetworkX/TF-IDF $\rightarrow$
integración de evidencia $\rightarrow$ redacción con LLM local.

La libreta de consultas leyó un archivo simple con cuatro columnas: identificador, tipo, pregunta y componentes consultados. En total se ejecutaron 20 preguntas: 10 descriptivas y 10 predictivas. La frecuencia de uso de motores fue la siguiente: SQL participó en 13 preguntas, TF-IDF en 10, grafo principal en 14 y subgrafo de coautoría en 11. Esto confirma que la mayoría de las preguntas no dependieron de una sola fuente, sino de la combinación de componentes tabulares, textuales y de grafo.

“`latex`”

10.4. Resultados de las preguntas descriptivas

Las preguntas descriptivas permitieron caracterizar la producción académica y las relaciones observadas en la base limpia.

- D1.** En 2024, las áreas con más artículos fueron IA con 50 artículos y SIAV con 43. En 2025, SIAV lideró con 73 artículos e IA quedó en segundo lugar con 67. Esto indica que las áreas con mayor actividad reciente son las relacionadas con inteligencia artificial, visión, señales e imágenes.
- D2.** Los autores con mayor producción dentro de las áreas revisadas incluyen a Helena Montserrat Gómez Adorno en IA, con 26 artículos; Gemma Bel Enguix en IA, con 19; Boris Escalante Ramírez en SIAV, con 14; y Armando Castañeda Rojano en TC, con 9. Este resultado permite identificar autores con alta presencia bibliográfica dentro de la base limpia.
- D3.** El artículo con mayor número de coautores fue *Efficient and reliable spike sorting from neural recordings with UMAP-based unsupervised nonlinear dimensionality reduction*, del área SIAV, con 11 coautores. También destacó *PCA-enhanced Speckle Interferometry with Bicubic Interpolation at the OAN-SPM México*, con 8 coautores. En conjunto, estos resultados muestran que los artículos con mayor coautoría se concentran principalmente en SIAV.
- D4.** Las keywords más frecuentes fueron *deep learning* y *machine learning*, ambas presentes en 36 artículos. También destacaron *artificial intelligence*, *computational linguistics*, *convolutional neural networks*, *computer vision* y *algorithms*. Estas keywords confirman la concentración temática en IA y SIAV.
- D5.** Para la keyword *image processing*, la nueva corrida señaló como afiliaciones relevantes al Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas y a la Facultad de Ingeniería. Este resultado amplía la lectura anterior, donde destacaba la Facultad de Ingeniería, y sugiere que la actividad relacionada con procesamiento de imágenes se concentra en dependencias con producción significativa en IA, señales, visión y cómputo aplicado.
- D6.** Los autores que conectan distintas áreas o afiliaciones incluyen a Helena Montserrat Gómez Adorno, Gemma Bel Enguix, Boris Escalante Ramírez, Gerardo Eugenio Sierra Martínez y Jimena Olveres Montiel. Su presencia en varias relaciones del grafo los vuelve relevantes para analizar comunidades de colaboración.
- D7.** Para la keyword *brain*, se recuperaron artículos asociados con actividad neural, tortuosidad 3D en estructuras cerebrales y corrección de atenuación en estudios PET cerebrales. Estos

resultados muestran cómo la capa textual y el grafo permiten conectar conceptos específicos con autores y artículos.

- D8.** ISBD y CC aparecen como áreas con producción reciente pero menor número de autores asociados. Esto puede indicar áreas menos densas dentro de la base o comunidades más pequeñas en el periodo analizado.
- D9.** Se detectaron autores con similitud temática que aún no aparecen como coautores. Entre los pares encontrados están Francisco Javier García Ugalde–Leonardo Faustinos Morales, Hiram Calvo–Jessica Barco y Ricardo Daniel Fernandez Noguez–Sofia Magdalena Borrel Miller. Estos pares fueron identificados mediante similitud TF-IDF y ausencia de coautoría directa.
- D10.** En la nueva corrida no se observaron evidencias claras de publicaciones duplicadas o variantes del mismo artículo al comparar título, DOI, URL, abstract y autores. El análisis identificó publicaciones relacionadas, como el caso de Armando Castañeda Rojano en el área TC, pero no las clasificó como duplicados exactos. Por ello, estos resultados deben interpretarse como candidatos de revisión textual, no como duplicados confirmados.

10.5. Resultados de las preguntas predictivas

Las preguntas predictivas se interpretan como consultas exploratorias para identificar candidatos preliminares de colaboración. No deben entenderse como predicciones garantizadas.

- P1.** Se identificó como candidato preliminar el par Helena Montserrat Gómez Adorno–Boris Escalante Ramírez. La nueva corrida indicó que no tienen artículos comunes y que comparten similitud temática en keywords como *classification*, *classification tasks*, *data augmentation*, *deep learning*, *diseases* y *graph neural networks*. Esto sugiere afinidad temática, aunque requiere revisión académica antes de interpretarse como recomendación de colaboración.
- P2.** Para autores poco conectados, la nueva corrida identificó como candidatos preliminares a Ulises Rodriguez Dominguez y Viktor Monroy. Ambos aparecen asociados con múltiples keywords compartidas con autores más productivos, lo que sugiere posibles señales de colaboración futura desde la similitud temática y la cercanía estructural.
- P3.** En el subgrafo de coautoría, el par Helena Montserrat Gómez Adorno–Boris Escalante Ramírez aparece como candidato preliminar de colaboración. La señal principal fue la ausencia de coautoría directa y la presencia de varias keywords compartidas relacionadas con clasificación, aprendizaje profundo, aumento de datos y modelos de grafos.
- P4.** Para artículos relacionados con *image processing*, se identificaron como candidatos preliminares Boris Escalante Ramírez–Helena Montserrat Gómez Adorno y Helena Montserrat Gómez Adorno–Jimena Olveres Montiel. La recomendación se basó en keywords compartidas y conectividad en el subgrafo.
- P5.** Dentro de una misma afiliación, se detectaron pares con keywords compartidas, como Boris Escalante Ramírez–Helena Montserrat Gómez Adorno y Helena Montserrat Gómez Adorno–Jimena Olveres Montiel. Este resultado puede apoyar búsquedas de colaboración interna.

- P6.** Entre afiliaciones distintas, se encontraron pares temáticamente cercanos como Francisco Javier García Ugalde–Leonardo Faustinos Morales e Hiram Calvo–Jessica Barco. En estos casos, la señal principal fue la similitud TF-IDF, no una relación de coautoría existente.
- P7.** Para autores poco conectados, la nueva corrida identificó varios pares candidatos alrededor de Ulises Rodríguez Domínguez. Entre ellos aparecen Lucas Bayones–Ulises Rodríguez Domínguez, Bernardo Andrade Ortega–Ulises Rodríguez Domínguez y Ulises Rodríguez Domínguez–Viktor Monroy, todos con 13 keywords compartidas. Estos resultados sugieren posibles conexiones temáticas para integrar autores poco conectados a grupos de colaboración, aunque deben revisarse como candidatos preliminares.
- P8.** Se identificó el par Helena Montserrat Gómez Adorno–Boris Escalante Ramírez como candidato preliminar, ya que ambos publicaron en 2024 dentro del área IA y comparten similitud temática en sus artículos. La nueva corrida reportó 12 keywords comunes entre ambos autores, por lo que el par puede considerarse una señal exploratoria de colaboración potencial.
- P9.** Dentro de la Facultad de Ingeniería, que aparece como una de las afiliaciones relevantes, se detectaron pares de autores de la misma área sin coautoría previa. Entre ellos se encuentran Alain Morales Martínez–Jimena Olvera Montiel y Boris Escalante Ramírez–Mario Roberto Arrieta Paternina.
- P10.** Se detectaron pares de autores sin coautoría previa con alta similitud temática, pero clasificados en áreas distintas. Entre ellos están Daniel Torres Robledo–Emmanuel Resendiz Ochoa, y Antonio Paulino Zainos Rosales–Ulises Rodríguez Domínguez. Estos casos pueden ser útiles para explorar colaboraciones interdisciplinarias.

10.6. Control de calidad del LLM

Para evitar respuestas inventadas, se configuraron reglas de control en los prompts. El LLM debía usar los códigos de área exactamente como aparecen en la base; no debía inventar autores, artículos, afiliaciones, DOI, URL, áreas, keywords ni cantidades; y no debía calcular totales nuevos si no estaban presentes en la evidencia. Además, las preguntas predictivas debían redactarse como resultados exploratorios o candidatos preliminares, no como predicciones definitivas.

La corrida final confirmó que las 20 preguntas fueron respondidas con LLM local activo, usando el modelo `qwen2.5:7b` mediante Ollama, sin API externa. Las respuestas se generaron a partir de evidencia calculada previamente con SQL, NetworkX y TF-IDF.

10.7. Dictamen del análisis

La etapa de análisis puede considerarse cerrada porque se prepararon los recursos, textuales y de grafo; se ejecutaron nuevamente las 20 preguntas del proyecto; se integró la evidencia calculada; y se generaron respuestas en lenguaje natural mediante un LLM local. Los resultados descriptivos permiten caracterizar áreas, autores, afiliaciones, keywords y artículos dentro de la base curada.

Los resultados predictivos deben interpretarse como señales exploratorias para identificar candidatos preliminares de colaboración. No representan predicciones definitivas ni recomendaciones automá-

ticas, ya que dependen de similitud temática, ausencia de coautoría previa, estructura del grafo y revisión posterior por criterio experto. En conjunto, el análisis muestra que la base final puede usarse para responder consultas heterogéneas siempre manteniendo validación humana sobre las respuestas generadas por el LLM.

11. Conclusiones

El proyecto permitió construir una base bibliográfica limpia, canónica y utilizable para análisis a partir de fuentes heterogéneas. El proceso partió de ocho fuentes bibliográficas: ACM Digital Library, EBSCO, Engineering Village, IEEE Xplore, ProQuest, ScienceDirect, Scopus y Web of Science. La recolección manual y la depuración preliminar produjeron 1,471 registros considerados pertenecientes a Ciencias de la Computación. Sin embargo, esta cifra no representaba todavía artículos únicos, sino una suma preliminar de registros por fuente y área, por lo que fue necesario aplicar integración, perfilado, limpieza, de-duplicación y fusión.

Una conclusión central del proyecto es que la integración de datos bibliográficos no puede resolverse únicamente juntando archivos CSV. Las fuentes utilizadas presentaban esquemas, formatos, nombres de campos, reglas de afiliación, disponibilidad de DOI, keywords, abstracts y autores con representaciones diferentes. Por esta razón, la transformación al modelo canónico fue una etapa indispensable para reducir la heterogeneidad entre fuentes y permitir que todos los registros pudieran analizarse bajo una misma estructura.

Durante la conversión canónica se revisaron 1,471 registros y se corrigió la clasificación temática de 768 registros. Esto demuestra que la carpeta o query inicial de búsqueda fue útil para recolectar información, pero no fue suficiente para asignar el área final de cada artículo. Fue necesario revisar el contenido bibliográfico, principalmente **Titulo**, **Keywords** y **Abstract**, para distinguir entre las seis áreas del proyecto: ISBD, CC, IA, TC, SIAV y RS.

El resultado final cumple con la lógica de calidad de datos esperada. La base conserva una fila por relación artículo–autor UNAM, mantiene las 14 columnas canónicas, no tiene filas sin autor, no tiene filas sin afiliación principal, no conserva áreas fuera de catálogo, no conserva áreas combinadas y presenta URL completas para todos los registros. Además, cada fase generó archivos, reportes o diagnósticos que permiten mantener trazabilidad metodológica sobre las decisiones tomadas.

Antes de la limpieza, un mismo artículo podía aparecer repetido en varias fuentes, un mismo autor podía tener múltiples variantes de nombre, y las afiliaciones podían estar incompletas, ser demasiado genéricas o aparecer en formatos incompatibles. Después del proceso de limpieza, normalización, de-duplicación, fusión y curaduría manual, la base permite analizar con mayor confianza quién publica, en qué área, con qué afiliación, sobre qué temas y con qué relaciones de coautoría.

La base también muestra que las oportunidades de colaboración académica no dependen únicamente de la productividad. Un autor con muchos artículos no necesariamente tiene la mayor conectividad en el grafo de coautoría, y un autor poco conectado puede ser temáticamente cercano a otros investigadores. La integración del modelo canónico, los campos textuales y los grafos permite identificar candidatos preliminares de colaboración con base en señales múltiples, como similitud temática, keywords compartidas, área de conocimiento, afiliación y ausencia de coautoría previa.

En términos generales, el proyecto logró pasar de fuentes bibliográficas heterogéneas a una base curada y preparada para análisis multimodelo. Esto confirma la importancia del preprocesamiento y de la calidad de datos antes de cualquier análisis descriptivo, predictivo o asistido por LLM. La base final no sólo funciona como un archivo integrado, sino como un insumo confiable para estudiar producción científica reciente de la UNAM en Ciencias de la Computación y para explorar posibles vínculos de colaboración académica.